


Hackeando uma IA

Técnicas de Ataque e Defesa em Modelos de Difusão


Prof. Jean Lima
Faculdade de Ciência e Tecnologia
UFMT – Campus Várzea Grande

IA é um termo muito amplo...




IA é um termo muito amplo...

Nosso escopo: Modelos de Difusão



IA é um termo muito amplo...

Nosso escopo: Modelos de Difusão




Um breve histórico




Década de 40-50

Surgimento da Ideia de IA. Primeiras ideias matemáticas de representação de Neurônio Biológico


Um breve histórico




Um breve histórico



Um breve histórico



Um breve histórico



Modelos de Difusão

Família de modelos de IA generativa que adiciona ruído em dados e aprende como reverter ao estado original.

Modelos de Difusão

Família de modelos de IA generativa que adiciona ruído em dados e aprende como reverter ao estado original.




Modelos de Difusão

Família de modelos de IA generativa que adiciona ruído em dados e aprende como reverter ao estado original.



Modelos de Difusão


Família de modelos de IA generativa que adiciona ruído em dados e aprende como reverter ao estado original.



Modelos de Difusão

Família de modelos de IA generativa que adiciona ruído em dados e aprende como reverter ao estado original.


Forward Diffusion



Modelos de Difusão


Família de modelos de IA generativa que adiciona ruído em dados e aprende como reverter ao estado original.

Forward Diffusion



Modelos de Difusão


Família de modelos de IA generativa que adiciona ruído em dados e aprende como reverter ao estado original.



Representação de Imagens




Representação de Imagens




Redimensionamento
(24x24)


Representação de Imagens




Redimensionamento
(24x24)




Representação de Imagens



Redimensionamento
(24x24)



Representação de Imagens



Redimensionamento
(24x24)

134	140	152	148	130	123	130	139	142	163	171	175	172	180	165	146	181	119	167	212	216	214	228	228
124	148	145	141	119	116	119	133	129	160	164	169	173	186	172	189	178	104	175	201	203	211	226	229
122	141	146	140	115	146	142	108	112	124	95	114	144	166	151	204	175	110	160	115	155	241	221	242
151	116	97	84	95	181	220	204	190	193	178	179	184	166	191	186	202	151	192	115	169	245	213	249
135	113	109	103	108	161	104	99	122	125	112	110	112	130	51	30	148	189	201	194	208	215	192	225
169	172	174	186	180	182	179	177	163	182	179	179	176	165	161	160	165	160	168	173	174	172	177	177
195	199	198	197	193	195	193	192	197	195	197	195	197	192	192	188	182	175	171	165	158	152	150	151
187	182	186	187	186	185	188	187	184	178	179	189	152	56	37	40	87	162	187	178	166	162	167	191
183	176	169	170	168	174	183	181	168	161	164	106	32	30	77	34	25	57	143	193	190	191	179	194
171	178	182	179	180	178	185	187	188	189	163	19	44	78	71	133	47	45	97	200	203	194	194	188
102	108	122	129	142	144	142	152	162	182	160	56	78	38	17	128	136	61	108	206	201	197	198	192
107	100	109	119	107	113	114	110	112	117	126	50	54	71	56	110	66	43	114	181	191	194	195	193
122	107	113	108	115	108	120	131	131	131	118	60	107	70	87	131	72	102	189	117	111	111	113	117
111	122	117	115	102	105	112	126	132	130	140	171	140	99	101	97	157	189	195	129	107	107	106	105
119	122	118	125	118	118	112	117	120	120	136	187	138	83	133	161	178	172	216	125	108	104	102	101
111	113	111	108	105	110	119	122	122	113	117	187	162	125	111	143	150	187	222	114	108	101	99	97
105	107	104	106	106	113	114	104	102	105	128	176	150	109	98	159	175	187	221	81	100	109	104	99
95	104	100	109	115	108	102	97	92	95	109	168	160	90	107	158	162	185	218	73	61	111	111	101
84	112	105	109	107	109	100	95	91	84	81	125	119	93	114	153	164	177	206	140	53	106	104	103
80	98	101	105	98	92	95	92	84	82	80	91	110	101	106	104	141	166	180	73	77	73	97	105
91	96	98	95	88	88	88	81	78	78	74	79	145	64	76	70	62	153	150	77	89	47	93	98
93	93	92	94	93	93	86	78	70	66	63	127	133	61	67	69	73	152	130	71	82	61	89	97
88	95	86	90	91	82	78	82	76	67	75	142	83	58	66	67	67	160	99	73	83	79	84	95
79	90	89	87	84	75	75	82	73	71	71	63	66	60	65	65	69	179	85	71	77	83	87	81


Ruído Gaussiano

Ruído aleatório cujos valores seguem uma Distribuição Normal (Distribuição Gaussiana).

Ruído Gaussiano

Ruído aleatório cujos valores seguem uma Distribuição Normal (Distribuição Gaussiana).


Distribuição Gaussiana



Ruído Gaussiano

Ruído aleatório cujos valores seguem uma Distribuição Normal (Distribuição Gaussiana).

Distribuição Gaussiana




Simplificando:

Modelo Estatístico de distribuição que os dados se organizam simetricamente ao redor de um valor central

Ruído Gaussiano

Ruído aleatório cujos valores seguem uma Distribuição Normal (Distribuição Gaussiana).

Distribuição Gaussiana



Complicando:

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Ruído Gaussiano em uma Imagem

Se $x(i,j)$ é o valor do pixel na posição (i,j) . A imagem observada com ruído é:

$$y(i, j) = x(i, j) + n(i, j)$$

onde

$$n(i, j) \sim N(\mu, \sigma^2)$$

Ruído Gaussiano em uma Imagem

100	200
50	150

X

Ruído Gaussiano em uma Imagem

100	200
50	150

 $+$

13	-17
-22	26

x

n

Ruído Gaussiano em uma Imagem

100	200	+	13	-17	=	113	183
50	150		-22	26		28	176
x			n			y	

Ruído Gaussiano em uma Imagem

100	200
50	150

+

13	-17
-22	26

=

113	183
28	176


x

n

y


Mean(X) =

Ruído Gaussiano em uma Imagem




$$\text{Mean}(X) = (100+200+50+150)/4$$

Ruído Gaussiano em uma Imagem



$$\text{Mean}(X) = (100+200+50+150)/4 \\ = 125$$


Ruído Gaussiano em uma Imagem



$$\text{Mean}(X) = (100+200+50+150)/4 \\ = 125$$

$$\text{Mean}(n) = ?$$


Ruído Gaussiano em uma Imagem



$$\text{Mean}(X) = (100+200+50+150)/4 \\ = 125$$

$$\text{Mean}(n) = 0$$

Ruído Gaussiano em uma Imagem



x

$$\text{Mean}(X) = (100+200+50+150)/4 \\ = 125$$


n

$$\text{Mean}(n) = 0$$

y

$$\text{Mean}(Y) = ?$$

Ruído Gaussiano em uma Imagem



x

$$\text{Mean}(X) = (100+200+50+150)/4 \\ = 125$$

n

$$\text{Mean}(n) = 0$$


y

$$\text{Mean}(Y) = 125$$



Ruído Gaussiano em uma Imagem





Ruído Gaussiano em uma Imagem



Ruído Gaussiano em uma Imagem



Ruído Gaussiano em uma Imagem




Mean(x) = 130.53


Ruído Gaussiano em uma Imagem



Mean(x) = 130.53




Mean(n) = 0.04




Ruído Gaussiano em uma Imagem



Mean(x) = 130.53



Mean(n) = 0.04




Mean(Y) = 129.86

Prática I

Processamento de Imagens + Ruído Gaussiano

Modelos de Difusão

Família de modelos de IA generativa que adiciona ruído em dados e aprende como reverter ao estado original.



Denoising Diffusion Probabilistic Model (DDPM)

Formalização:

(i) **Forward Diffusion:** Adição sequencial de ruído gaussiano;

$$\mathbf{x}_0 \rightarrow \mathbf{x}_1 \rightarrow \mathbf{x}_2 \rightarrow \cdots \rightarrow \mathbf{x}_t$$

(ii) **Reverse Diffusion:** Estimação do ruído por meio de redes neurais

Forward Diffusion

Noise Schedule:

Variável de controle de quantidade de ruído adicionado a cada etapa.

$$\beta = [\beta_1, \beta_2, \beta_3, \dots, \beta_t]$$

Ex: $\beta = [0,01; 0,02; 0,03; 0,04] \rightarrow \text{Linear}$

Forward Diffusion

Noise Schedule:

Se β representa a proporção de ruído a ser considerado, podemos representar a porção do sinal original como:

$$\alpha_t = 1 - \beta_t$$

e, portanto:

$$\alpha_t + \beta_t = 1$$

Forward Diffusion

Generalização:

Assim, para qualquer passo t da difusão direta, podemos obter x_t seguindo a equação:

$$x_t = \left(\sqrt{\alpha_t}\right)x_0 + \left(\sqrt{1 - \alpha_t}\right)\epsilon$$

Forward Diffusion

Generalização:

Assim, para qualquer passo t da difusão direta, podemos obter x_t seguindo a equação:

$$x_t = \left(\sqrt{\alpha_t} \right) x_0 + \left(\sqrt{1 - \alpha_t} \right) \epsilon$$

Sinal Original

Forward Diffusion

Generalização:

Assim, para qualquer passo t da difusão direta, podemos obter x_t seguindo a equação:

$$x_t = \left(\sqrt{\alpha_t} \right) x_0 + \left(\sqrt{1 - \alpha_t} \right) \epsilon$$

Sinal Original Ruído

Forward Diffusion

Generalização:

Assim, para qualquer passo t da difusão direta, podemos obter x_t seguindo a equação:

$$x_t = \underbrace{\left(\sqrt{\alpha_t}\right)}_{\text{Quantidade de Sinal Preservado}} \overset{\text{Sinal Original}}{\circledast} x_0 + \left(\sqrt{1 - \alpha_t}\right) \overset{\text{Ruído}}{\circledast} \epsilon$$

Forward Diffusion

Generalização:

Assim, para qualquer passo t da difusão direta, podemos obter x_t seguindo a equação:

$$x_t = \underbrace{\left(\sqrt{\widehat{\alpha}_t}\right)}_{\text{Quantidade de Sinal Preservado}} \underbrace{x_0}_{\text{Sinal Original}} + \underbrace{\left(\sqrt{1 - \widehat{\alpha}_t}\right)}_{\text{Quantidade de Ruído Acumulado}} \underbrace{\epsilon}_{\text{Ruído}}$$

Forward Diffusion


Generalização:

Assim, para qualquer passo t da difusão direta, podemos obter x_t seguindo a equação:

$$x_t = \underbrace{\left(\sqrt{\hat{\alpha}_t}\right)}_{\text{Quantidade de Sinal Preservado}} \underbrace{x_0}_{\text{Sinal Original}} + \underbrace{\left(\sqrt{1 - \hat{\alpha}_t}\right)}_{\text{Quantidade de Ruído Acumulado}} \underbrace{\epsilon}_{\text{Ruído}}$$


* Na prática não precisamos treinar todos os passos de difusão, podemos amostrar alguns t .

Reverse Diffusion




Reverse Diffusion

Atributos Preditores




Reverse Diffusion

Atributos Preditores




Atributo Alvo



$$\epsilon_{\theta}(x_t, t)$$

Reverse Diffusion

Atributos Preditores



x_t

t

Rede Neural

$\epsilon_{\theta}(x_t, t)$




ϵ

Atributo Alvo


Reverse Diffusion

Atributos Preditores



x_t

t



Rede Neural

$\epsilon_{\theta}(x_t, t)$




ϵ

Atributo Alvo


Comparação para
atualização de Parâmetros

Reverse Diffusion




Reverse Diffusion

Atributos Preditores



x_t

t



Rede Neural

$\epsilon_{\theta}(x_t, t)$



ϵ

Atributo Alvo

Comparação para
atualização de Parâmetros

Função de Perda

Ex:


$$\mathcal{L} = \|\epsilon - \epsilon_{\theta}(x_t, t)\|^2$$

Prática II

Pré-Processamento DDPM


Geração

Execução, Inferência, etc




Geração

Execução, Inferência, etc




Geração

Execução, Inferência, etc




Geração

Execução, Inferência, etc




Geração

Execução, Inferência, etc




Geração

Execução, Inferência, etc



Modelos de Difusão

Família de modelos de IA generativa que adiciona ruído em dados e aprende como reverter ao estado original.




E essa rede neural?


U-Net

- Rede Neural Convolutacional proposta em 2015;
- Usada originalmente para tarefas de segmentação de imagens;
- Adaptada para DDPM:
 - Classificação $\rightarrow$ Regressão


U-Net



U-Net



U-Net







Atacando o Modelo

Membership Inference (Inferência de Pertencimento)

- Técnica Escolhida: ***Loss-based Membership Inference Attack***
- Tipo de Ataque: White-box

- **Hipótese:**

O modelo costuma prever melhor o ruído de imagens que viu durante o treinamento

Isto é:

Loss pequena → Provável Membro

Loss grande → Provável Não Membro

Prática III

Membership Inference

https://github.com/jpdol/SEMATEC2026_ModelPrivacy

Possíveis Estratégias de Defesa



- Evitar overfitting;
- Aumento de Dados;
- Regularização;
- Deduplicação dos Dados;
- Controlar acesso ao modelo;
- Privacidade Diferencial.

Considerações Finais



- Existe uma infinidade de outras técnicas de ataques a modelos de IA, incluindo Modelos de Difusão (White-box e black-box);
- Modelos de difusão estão no estado da arte generativa (evoluções do DDPM), tanto com abordagens Não Condicionais quanto Condicionais;
- Ataques mais robustos aumentam consideravelmente o tempo de processamento

Referências Sugeridas

Para Fortalecer a base



Para avançar nos estudos



Para ir além...

Denoising Diffusion Probabilistic Models

Jonathan Ho
UC Berkeley
jonathanho@berkeley.edu

Ajay Jain
UC Berkeley
ajayj@berkeley.edu

Pieter Abbeel
UC Berkeley
pabbeel@cs.berkeley.edu

Abstract

We present high-quality image synthesis results using diffusion probabilistic models, a class of latent variable models inspired by considerations from nonequilibrium thermodynamics. Our best results are obtained by training on a weighted variational bound designed according to a novel connection between diffusion probabilistic models and denoising score matching with Langevin dynamics, and our models naturally admit a progressive lossy decomposition scheme that can be interpreted as a generalization of autoregressive decoding. On the unconditional CIFAR10 dataset, we obtain an Inception score of 9.46 and a state-of-the-art FID score of 3.17. On 256x256 LSUN, we obtain sample quality similar to ProgressiveGAN. Our implementation is available at <https://github.com/hojonathanho/diffusion>.

1 Introduction

Deep generative models of all kinds have recently exhibited high quality samples in a wide variety of data modalities. Generative adversarial networks (GANs), autoregressive models, flows, and variational autoencoders (VAEs) have synthesized striking image and audio samples [14, 27, 3, 58, 38, 25, 10, 32, 44, 57, 26, 33, 45], and there have been remarkable advances in energy-based modeling and score matching that have produced images comparable to those of GANs [11, 55].




Figure 1: Generated samples on CelebA-HQ 256×256 (left) and unconditional CIFAR10 (right)

34th Conference on Neural Information Processing Systems (NeurIPS 2020), Vancouver, Canada.

FORTHCOMING FROM MIT Press, 2027

The Principles of Diffusion Models

Chieh-Hsin Lai
Sony AI

Yang Song
OpenAI

Dongjun Kim
Stanford University

Yuki Mitsufuji
Sony Group Corporation, Sony AI

Stefano Ermon
Stanford University

Membership Inference of Diffusion Models

Hailong Hu¹ and Jun Pang^{2,1}

¹ StT, University of Luxembourg, Esch-sur-Alzette, Luxembourg

² FSTM, University of Luxembourg, Esch-sur-Alzette, Luxembourg

Abstract. Recent years have witnessed the tremendous success of diffusion models in data synthesis. However, when diffusion models are applied to sensitive data, they also give rise to severe privacy concerns. In this paper, we systematically present the first study about membership inference attacks against diffusion models, which aims to infer whether a sample was used to train the model. Two attack methods are proposed, namely loss-based and likelihood-based attacks. Our attack methods are evaluated on several state-of-the-art diffusion models, over different datasets in relation to privacy-sensitive data. Extensive experimental evaluations show that our attacks can achieve remarkable performance. Furthermore, we exhaustively investigate various factors which can affect attack performance. Finally, we also evaluate the performance of our attack methods on diffusion models trained with differential privacy.

1 Introduction

Diffusion models [34] have recently made remarkable progress in image synthesis [15, 18, 39], even being able to generate better-quality images than generative adversarial networks (GANs) [10] in some situations [8]. They have also been applied to sensitive personal data, such as the human face [18, 38] or medical images [20, 29], which might unwittingly lead to the leakage of training data. As a consequence, it is paramount to study privacy breaches in diffusion models.

Membership inference (MI) attacks aim to infer whether a given sample was used to train the model [33]. In practice, they are widely applied to analyze the privacy risks of a machine learning model [25, 36]. To date, a growing number of studies concentrate on classification models [3, 24, 32, 33, 42], GANs [6, 12], text-to-image generative models [41], and language models [4, 5]. However, there is still a lack of work on MI attacks against diffusion models. In addition, data protection regulations, such as GDPR [28], require that it is mandatory to assess privacy threats of technologies when they are involving sensitive data. Therefore, all of these drive us to investigate the membership vulnerability of diffusion models.

In this paper, we systematically study the problem of membership inference of diffusion models. Specifically, we consider two threat models: in threat model I, adversaries are allowed to obtain the target diffusion model, which means that adversaries can calculate the loss values of a sample through the model. This scenario usually occurs when institutions share a generative model with their collaborators to avoid directly sharing original data [23, 27]. We emphasize that

Valeu, pessoal!



Hackeando uma IA

Técnicas de Ataque e Defesa em Modelos de Difusão

Prof. Jean Lima
jean.lima1@ufmt.br

Faculdade de Ciência e Tecnologia
UFMT – Campus Várzea Grande